

## 2.4 선형 연립방정식과 역행렬

선형 예측모형은 입력 데이터 벡터와 가중치 벡터의 내적으로 계산된 예측값이 실제 출력 데이터와 유사한 값을 출력하도록 하는 모형이다. 그럼 올바른 가중치 벡터는 어떻게 구할 수 있을까? 여기에서는 연립방정식과 역행렬을 이용하여 선형 예측모형의 가중치 벡터를 구하는 방법을 알아본다.

### 선형 연립방정식

복수의 미지수를 포함하는 복수의 선형 방정식을 **선형 연립방정식(system of linear equations)** 또는 연립일차방정식이라고 한다.

다음은 3개의 미지수와 3개의 선형 방정식을 가지는 선형 연립방정식의 한 예다.

$$\begin{aligned} x_1 + x_2 &= 2 \\ x_2 + x_3 &= 2 \\ x_1 + x_2 + x_3 &= 3 \end{aligned} \quad (2.4.1)$$

$x_1, x_2, \dots, x_M$  이라는  $M$  개의 미지수를 가지는  $N$ 개의 선형 연립방정식은 일반적으로 다음과 같은 형태가 된다. 이 식에서  $a$ 와  $b$ 는 방정식의 계수다.

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \dots + a_{1M}x_M &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2M}x_M &= b_2 \\ \vdots &\vdots \\ a_{N1}x_1 + a_{N2}x_2 + \dots + a_{NM}x_M &= b_N \end{aligned} \quad (2.4.2)$$

행렬과 벡터의 곱셈을 이용하면 위 선형 연립방정식은 다음처럼 간단하게 쓸 수 있다.

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1M} \\ a_{21} & a_{22} & \cdots & a_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ a_{N1} & a_{N2} & \cdots & a_{NM} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_M \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_N \end{bmatrix} \quad (2.4.3)$$

이 식에서

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1M} \\ a_{21} & a_{22} & \cdots & a_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ a_{N1} & a_{N2} & \cdots & a_{NM} \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_M \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_N \end{bmatrix} \quad (2.4.4)$$

라고 하면 다음처럼 쓸 수 있다.

$$Ax = b \quad (2.4.5)$$

$A, x, b$  는 각각 **계수행렬(coefficient matrix)**, **미지수벡터(unknown vector)**, **상수벡터(constant vector)**라고 부른다.

이 표현을 따르면 앞에서 예로 든 선형 연립방정식은 다음처럼 표현할 수 있다.

$$Ax = b \quad (2.4.6)$$

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 2 \\ 3 \end{bmatrix} \quad (2.4.7)$$

만약  $A, x, b$ 가 행렬이 아닌 스칼라 실수라면 이 방정식은 나눗셈을 사용하여 다음처럼 쉽게 풀 수도 있을 것이다.

$$x = \frac{b}{A} \quad (2.4.8)$$

그러나 행렬에서는 나눗셈이 정의되지 않으므로 이 방법은 사용할 수 없다. 행렬에서는 나눗셈 대신 역행렬이라는 것을 사용한다.

## 역행렬

정방 행렬  $A$ 에 대한 **역행렬(inverse matrix)**  $A^{-1}$ 은 원래의 행렬  $A$ 와 다음 관계를 만족하는 정방 행렬을 말한다.  $I$ 는 항등 행렬(identity matrix)이다.

$$A^{-1}A = AA^{-1} = I \quad (2.4.9)$$

역행렬은 항상 존재하는 것이 아니라 **행렬  $A$ 에 따라서는 존재하지 않을 수도 있다**. 역행렬이 존재하는 행렬을 **가역행렬(invertible matrix)**, 정칙행렬(regular matrix) 또는 비특이행렬(non-singular matrix)이라고 한다. 반대로 역행렬이 존재하지 않는 행렬을 비가역행렬(non-invertible matrix) 또는 **특이행렬(singular matrix)**, 퇴화행렬(degenerate matrix)이라고 한다.

### 연습 문제 2.4.1

대각행렬의 역행렬은 각 대각성분의 역수로 이루어진 대각행렬과 같다.

$$\begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_N \end{bmatrix}^{-1} = \begin{bmatrix} \frac{1}{\lambda_1} & 0 & \cdots & 0 \\ 0 & \frac{1}{\lambda_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{\lambda_N} \end{bmatrix} \quad (2.4.10)$$

$N = 3$ 일 때 위 식을 증명하라.

## 역행렬의 성질

역행렬은 다음 성질을 만족한다. 이 식에서 행렬  $A, B, C$ 는 모두 각각 역행렬  $A^{-1}, B^{-1}, C^{-1}$ 이 존재한다고 가정한다.

- 전치 행렬의 역행렬은 역행렬의 전치 행렬과 같다. 따라서 대칭 행렬의 역행렬도 대칭 행렬이다.

$$(A^T)^{-1} = (A^{-1})^T \quad (2.4.11)$$

- 두 개 이상의 정방 행렬의 곱은 같은 크기의 정방 행렬이 되는데 이러한 행렬의 곱의 역행렬은 다음 성질이 성립한다.

$$(AB)^{-1} = B^{-1}A^{-1} \quad (2.4.12)$$

$$(ABC)^{-1} = C^{-1}B^{-1}A^{-1} \quad (2.4.13)$$

## 역행렬의 계산

역행렬은 행렬식을 이용하여 다음처럼 계산할 수 있다. 증명은 생략한다.

$$A^{-1} = \frac{1}{\det(A)} C^T = \frac{1}{\det(A)} \begin{bmatrix} C_{1,1} & \cdots & C_{N,1} \\ \vdots & \ddots & \vdots \\ C_{1,N} & \cdots & C_{N,N} \end{bmatrix} \quad (2.4.14)$$

이 식에서  $C_{i,j}$ 는  $A$ 의  $i, j$ 번째 원소에 대해 정의한 코팩터(cofactor)다.

코팩터로 이루어진 행렬  $C$ 을 **여인수행렬(matrix of cofactors, 또는 cofactor matrix, comatrix)**이라고 한다. 또 여인수행렬의 전치행렬  $C^T$ 를 **어드조인트행렬(adjoint matrix, adjugate matrix, 수반행렬)**이라고 하며  $\text{adj}(A)$ 로 표기하기도 한다.

위 식에서  $\det(A) = 0$ 이면 역수가 존재하지 않으므로 **역행렬은 행렬식이 0이 아닌 경우에만 존재한다**는 것을 알 수 있다.

### 연습 문제 2.4.2

코팩터 식을 사용하여 다음 공식을 증명하라.

$$\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}^{-1} = \frac{1}{a_{11}a_{22} - a_{12}a_{21}} \begin{bmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{bmatrix} \quad (2.4.15)$$

### 연습 문제 2.4.3

다음 역행렬을 계산하라.

(1)

$$\begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}^{-1} \quad (2.4.16)$$

(2)

$$\begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}^{-1} \quad (2.4.17)$$

(3)

$$\begin{bmatrix} \frac{3}{\sqrt{13}} & -\frac{1}{\sqrt{2}} \\ \frac{2}{\sqrt{13}} & \frac{1}{\sqrt{2}} \end{bmatrix}^{-1} \quad (2.4.18)$$

(4)

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}^{-1} \quad (2.4.19)$$

#### 연습 문제 2.4.4

두 정방행렬  $A, B$ 에 대해서  $AB = I$ 이면  $BA = I$ 임을 증명하라.

$$AB = I \rightarrow BA = I \quad (2.4.20)$$

### 역행렬에 대한 정리

역행렬에 대한 몇 가지 정리를 알아두면 도움이 된다.

#### 셔먼-모리슨(Sherman–Morrison) 공식

정방행렬  $A$ 와 벡터  $u, v$ 에 대해 다음 공식이 성립한다.

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u} \quad (2.4.21)$$

#### 우드베리(Woodbury) 공식

정방행렬  $A$ 와 이에 대응하는 적절한 크기의 행렬  $U, V, C$ 에 대해 다음 공식이 성립한다.

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1} \quad (2.4.22)$$

#### 분할행렬의 역행렬

4개 블록(block)으로 분할된 행렬(partitioned matrix)의 역행렬은 각 분할행렬을 이용하여 계산할 수 있다.

$$\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}^{-1} = \begin{bmatrix} A_{11}^{-1}(I + A_{12}FA_{11}^{-1}) & -A_{11}^{-1}A_{12}F \\ -FA_{21}A_{11}^{-1} & F \end{bmatrix} \quad (2.4.23)$$

이 식에서  $F$ 는 다음과 같이 주어진다.

$$F = (A_{22} - A_{21}A_{11}^{-1}A_{12})^{-1} \quad (2.4.24)$$

또는

$$F = (A_{11} - A_{12}A_{22}^{-1}A_{21})^{-1} \quad (2.4.25)$$

### 넘파이를 사용한 역행렬 계산

넘파이의 linalg 서브패키지에는 역행렬을 구하는 `inv()` 라는 명령어가 존재한다. 앞에서 예로 든 선형 연립 방정식의 행렬  $A$ 의 역행렬은 다음처럼 구할 수 있다.

In [1]:

```
import numpy as np

A = np.array([[1, 1, 0], [0, 1, 1], [1, 1, 1]])
A
```

Out[1]:

```
array([[1, 1, 0],
       [0, 1, 1],
       [1, 1, 1]])
```

In [2]:

```
Ainv = np.linalg.inv(A)
Ainv
```

Out[2]:

```
array([[ 0., -1.,  1.],
       [ 1.,  1., -1.],
       [-1.,  0.,  1.]])
```

## 역행렬과 선형 연립방정식의 해

선형 연립방정식에서 미지수의 수와 방정식의 수가 같다면 계수행렬  $A$ 는 정방행렬이 된다. 만약 행렬  $A$ 의 역행렬  $A^{-1}$ 이 존재한다면 역행렬의 정의로부터 선형 연립방정식의 해는 다음처럼 구할 수 있다. 행렬과 벡터의 순서에 주의하라.

$$\begin{aligned} Ax &= b & (2.4.26) \\ A^{-1}Ax &= A^{-1}b & (2.4.27) \\ Ix &= A^{-1}b & (2.4.28) \\ x &= A^{-1}b & (2.4.29) \end{aligned}$$

넘파이를 이용하여 앞에서 예로 든 선형 연립방정식의 해  $x$ 를 구하는 방법은 다음과 같다.

In [3]:

```
b = np.array([2], [2], [3]))
b
```

Out[3]:

```
array([[2],
       [2],
       [3]])
```

In [4]:

```
x = Ainv @ b
x
```

Out[4]:

```
array([[1.],
       [1.],
       [1.]])
```

이 벡터를 원래의 연립방정식에 대입하여 상수벡터  $b$ 와 값이 일치하는지 확인해보자.

In [5]:

```
A @ x - b
```

Out[5]:

```
array([[0.],
       [0.],
       [0.]])
```

`lstsq()` 명령은 행렬  $A$ 와  $b$ 를 모두 인수로 받고 뒤에서 설명할 최소자승문제(least square problem)의 답  $x$ , 잔차제곱합(residual sum of squares) `resid`, 랭크(rank) `rank`, 특잇값(singular value) `s`를 반환한다. 미지수와 방정식의 개수가 같고 행렬  $A$ 의 역행렬이 존재하면 최소자승문제의 답과 선형 연립방정식의 답이 같으므로 `lstsq()` 명령으로 선형 연립방정식을 풀 수도 있다. 최소자승문제, 랭크, 특잇값에 대해서는 뒤에서 자세히 설명할 것이다.

다음 코드에서 `lstsq()` 명령으로 구한 답이 `inv()` 명령으로 구한 답과 같음을 알 수 있다.

In [6]:

```
x, resid, rank, s = np.linalg.lstsq(A, b)
x
```

Out[6]:

```
array([[1.],
       [1.],
       [1.]])
```

`lstsq()` 명령을 사용하는 것이 `inv()` 명령을 사용하는 것보다 수치오차가 적고 코드도 간단하므로 선형 연립방정식의 해를 구할 때도 `lstsq()` 명령을 사용하는 것을 권장한다.

## 선형 연립방정식과 선형 예측모형

선형 예측모형의 가중치벡터를 구하는 문제는 선형 연립방정식을 푸는 것과 같다. 예를 들어  $N$ 개의 입력차원을 가지는 특징벡터  $N$ 개를 입력 데이터로 이용하고 이 입력에 대응하는 목표값벡터를 출력하는 선형 예측모형을 생각하자.

$$\begin{array}{ccccccc} x_{11}w_1 & + & x_{12}w_2 & + \cdots + & x_{1N}w_N & = & y_1 \\ x_{21}w_1 & + & x_{22}w_2 & + \cdots + & x_{2N}w_N & = & y_2 \\ \vdots & & \vdots & & \vdots & & \vdots \\ x_{N1}w_1 & + & x_{N2}w_2 & + \cdots + & x_{NN}w_N & = & y_N \end{array} \quad (2.4.30)$$

즉,

$$Xw = y \quad (2.4.31)$$

이 예측 모형의 가중치벡터  $w$ 를 찾는 것은 계수행렬이  $X$ , 미지수벡터가  $w$ , 상수벡터가  $y$ 인 선형 연립방정식의 답을 찾는 것과 같다. 그리고 만약 계수행렬, 여기에서는 특징행렬  $X$ 의 역행렬  $X^{-1}$ 이 존재하면 다음처럼 가중치벡터를 구할 수 있다.

$$w = X^{-1}y \quad (2.4.32)$$

### 연습 문제 2.4.5

보스턴 집값 문제는 미국 보스턴내 각 지역(town)의 주택 가격을 그 지역의 범죄율이나 공기 오염도 등의 특징을 사용하여 예측하는 문제다. Scikit-Learn 패키지에서 임포트할 수 있다. 보스턴 집값 문제를 선형 예측모형  $Ax = \hat{b}$ 로 풀었을 때의 가중치 벡터  $x$ 를 구하라. 행렬과 벡터 데이터는 다음과 같이 얻을 수 있다. 여기에서는 문제를 간단하게 하기 위해 입력 데이터를 범죄율(CRIM), 공기 오염도(NOX), 방의 개수(RM), 오래된 정도(AGE)의 4종류로 제한했고 데이터도 4개만 사용했다.

```
from sklearn.datasets import load_boston
boston = load_boston()
X = boston.data
y = boston.target
A = X[:4, [0, 4, 5, 6]] # 'CRIM', 'NOX', 'RM', 'AGE'
b = y[:4]
```

이렇게 구한 가중치의 크기나 부호가 우리의 직관이나 경험과 일치하는지 살펴보라.

### 미지수의 수와 방정식의 수



지금까지는 미지수의 수와 방정식의 수가 같은 선형 연립방정식에 대해서만 생각했다. 그런데 만약 미지수의 수와 방정식의 수가 다르다면 어떻게 해야 할까?

미지수의 수와 방정식의 수를 고려해 볼 때 연립방정식에는 다음과 같은 세 종류가 있을 수 있다.

1. 방정식의 수가 미지수의 수와 같다. ( $N = M$ )
2. 방정식의 수가 미지수의 수보다 적다. ( $N < M$ )
3. 방정식의 수가 미지수의 수보다 많다. ( $N > M$ )

1번의 경우, 즉 방정식의 수가 미지수의 수와 같은 경우는 앞에서 다루었다.

2번의 경우, 즉 방정식의 수가 미지수의 수보다 적을 때는 무수히 많은 해가 존재할 수 있다. 예를 들어 다음 선형 연립방정식을 생각해 보자. 미지수는 3개지만 방정식은 2개뿐이다.

$$\begin{aligned} x_1 + x_2 &= 2 \\ x_2 + x_3 &= 2 \end{aligned} \quad (2.4.33)$$

이때는  $x_2$ 가 어떤 값이 되더라도  $x_1 = x_3 = 2 - x_2$ 만 만족하면 되므로 무한히 많은 해가 존재한다. 예를 들어 다음  $x$  벡터는 모두 위 선형 연립방정식의 해다.

$$x = \begin{bmatrix} 2 \\ 0 \\ 2 \end{bmatrix}, \quad x = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \quad x = \begin{bmatrix} 0 \\ 2 \\ 0 \end{bmatrix}, \quad \dots \quad (2.4.34)$$

3번의 경우, 즉 방정식의 수가 미지수의 수보다 많을 때는 2번과 반대로 모든 조건을 만족하는 해가 하나도 존재할 수 없을 수 있다. 예를 들어 다음 선형 연립방정식을 생각해 보자. 미지수는 3개지만 방정식은 4개다.

$$\begin{aligned} x_1 + x_2 &= 2 \\ x_2 + x_3 &= 2 \\ x_1 + x_2 + x_3 &= 3 \\ x_1 + x_2 + 2x_3 &= 5 \end{aligned} \quad (2.4.35)$$

위의 3개 방정식을 동시에 만족하는 해는  $x_1 = x_2 = x_3 = 1$ 인데 이 값은 4번째 방정식을 만족하지 못한다.

$$x_1 + x_2 + 2x_3 = 4 \quad (2.4.36)$$

따라서 4개의 방정식을 모두 만족하는 해는 존재하지 않는다.

선형 예측모형을 구하는 문제는 계수행렬이 특징행렬  $X$ , 미지수벡터가 가중치벡터  $w$ 인 선형 연립방정식 문제이다. 그런데 보통 데이터의 수는 입력차원보다 큰 경우가 많다. 예를 들어 면적, 층수, 한강이 보이는지의 여부로 집값을 결정하는 모형을 만들기 위해서 딱 3가구의 아파트 가격만 조사하는 경우는 없을 것이다. 보통은 10 가구 혹은 100 가구의 아파트 가격을 수집하여 이용하는 것이 일반적이다. 다시 말해 선형 예측모형을 구할 때는 3번과 같은 경우가 많다는 것을 알 수 있다.

이때는 선형 연립방정식의 해가 존재하지 않으므로 선형 연립방정식을 푸는 방식으로는 선형 예측모형의 가중치벡터를 구할 수 없다.

## 최소자승문제

이렇게 선형 연립방정식의 해가 존재하지 않는다면 선형 예측모형은 어떻게 구할까? 모형을 구하는 것을 포기해야 하는가? 그럴 필요는 없다. 이 문제에 대한 힌트를 얻기 위해 다음과 같은 선형 연립방정식을 생각해보자.

$$\begin{aligned} x_1 + x_2 &= 2 \\ x_2 + x_3 &= 2 \\ x_1 + x_2 + x_3 &= 3 \\ x_1 + x_2 + 2x_3 &= 4.1 \end{aligned} \quad (2.4.37)$$

위에서 보았듯이 이 선형 연립방정식의 해는 존재하지 않는다.

하지만 꼭 양변이 **정확하게 똑같지 않아도 된다면** 어떨까?  $x_1 = x_2 = x_3 = 1$ 를 위 방정식에 대입하면 결과는 다음과 같다.

$$\begin{aligned} x_1 + x_2 &= 2 \\ x_2 + x_3 &= 2 \\ x_1 + x_2 + x_3 &= 3 \\ x_1 + x_2 + 2x_3 &= 4 \approx 4.1 \end{aligned} \quad (2.4.38)$$

선형 예측모형에서 좌변을 예측값, 우변을 목표값이라고 생각한다면 100% 정확히 예측하지는 못했지만 상당히 비슷하게 예측한 값이라고 할 수 있다.

따라서 미지수의 개수보다 방정식의 개수가 많아서 선형 연립방정식으로 풀수 없는 문제는 좌변과 우변의 차이를 최소화하는 문제로 바꾸어 풀 수 있다. 앞서 예측값과 목표값의 차이를 잔차(residual)라고 한다고 했다.

$$e = Ax - b \quad (2.4.39)$$

잔차는 벡터이므로 최소자승문제에서는 벡터의 크기 중에서 **벡터의 놈(norm)을 최소화**하는 문제를 푼다. 앞 절에서 놈을 최소화하는 것은 놈의 제곱을 최소화하는 것과 같다고 했다. 여기에서는 잔차제곱합이 놈의 제곱이 된다.

$$e^T e = \|e\|^2 = (Ax - b)^T (Ax - b) \quad (2.4.40)$$

이 값을 최소화하는  $x$ 값은 수식으로 다음처럼 표현한다.

$$x = \arg \min_x e^T e = \arg \min_x (Ax - b)^T (Ax - b) \quad (2.4.41)$$

위 식에서  $\arg \min_x f(x)$ 는 함수  $f(x)$ 를 가장 작게 만드는  $x$ 값을 의미한다. 이러한 문제를 **최소자승문제 (least square problem)**라고 한다.

$A^T A$ 가 항상 정방 행렬이 된다는 점을 이용하여 다음과 같이 최소 자승 문제의 답이 어떤 형태가 되는지 살펴보자. 여기에서는 답의 형태만 살펴보고 엄밀한 증명은 하지 않을 것이다.

$$Ax \approx b \quad (2.4.42)$$

이 식의 양변에  $A^T$ 를 곱하면 각각  $A^T Ax$ 와  $A^T b$ 가 된다. 이 두 개의 벡터의 값이 같다고 일단 가정하자.

$$A^T Ax = A^T b \quad (2.4.43)$$

만약 정방 행렬  $A^T A$ 의 역행렬  $(A^T A)^{-1}$ 이 존재한다면

$$(A^T A)^{-1} (A^T A)x = (A^T A)^{-1} A^T b \quad (2.4.44)$$

이 식을 정리하면 다음과 같다.

$$x = ((A^T A)^{-1} A^T) b \quad (2.4.45)$$

위에서 보인 것은 수학적 증명이라고 할 수 없지만 엄밀한 수학적 증명을 통해 최소자승문제의 해를 구해도 위와 같은 결과를 얻을 수 있다. 자세한 내용은 행렬의 미분과 최적화를 공부한 뒤에 다루도록 한다.

여기에서 행렬  $(A^T A)^{-1} A^T$ 를 행렬  $A$ 의 **의사역행렬(pseudo inverse)**이라고 하며 다음처럼  $A^+$ 로 표기한다.

$$A^+ = (A^T A)^{-1} A^T \quad (2.4.46)$$

$$x = A^+b \quad (2.4.47)$$

넘파이의 `lstsq()` 명령은 사실 이러한 최소자승문제를 푸는 명령이다.

위에서 예로 든 선형 연립방정식을 넘파이를 사용하여 풀어보자.

In [7]:

```
A = np.array([[1, 1, 0], [0, 1, 1], [1, 1, 1], [1, 1, 2]])  
A
```

Out[7]:

```
array([[1, 1, 0],  
       [0, 1, 1],  
       [1, 1, 1],  
       [1, 1, 2]])
```

In [8]:

```
b = np.array([[2], [2], [3], [4.1]])  
b
```

Out[8]:

```
array([[2. ],  
       [2. ],  
       [3. ],  
       [4.1]])
```

우선 의사역행렬을 직접 계산하여 해를 구해보자.

In [9]:

```
Apinv = np.linalg.inv(A.T @ A) @ A.T  
Apinv
```

Out[9]:

```
array([[ 0.33333333, -1.          ,  0.33333333,  0.33333333],  
       [ 0.5         ,  1.          ,  0.          , -0.5         ],  
       [-0.5         ,  0.          ,  0.          ,  0.5         ]])
```

In [10]:

```
x = Apinv @ b  
x
```

Out[10]:

```
array([[1.03333333],  
       [0.95       ],  
       [1.05       ]])
```

이 해를 이용하여  $b$ 값을 구하면 다음처럼 우변과 소수점 아래 한자리 오차내에 있는 것을 볼 수 있다.

In [11]:

```
A @ x
```

Out[11]:

```
array([[1.98333333],
       [2.         ],
       [3.03333333],
       [4.08333333]])
```

lstsq() 명령으로 바로 구해도 같은 값이 나온다.

In [12]:

```
x, resid, rank, s = np.linalg.lstsq(A, b)
x
```

Out[12]:

```
array([[1.03333333],
       [0.95       ],
       [1.05       ]])
```

위 코드에서 resid 는 잔차벡터의  $e = Ax - b$ 의 제곱합, 즉 놈의 제곱이다.

In [13]:

```
resid, np.linalg.norm(A @ x - b) ** 2
```

Out[13]:

```
(array([0.00166667]), 0.001666666666666655)
```

### 연습 문제 2.4.6

보스턴 집값 문제를 선형 예측모형  $Xw = \hat{y}$ 로 풀었을 때의 가중치벡터  $w$ 를 최소 자승 방법으로 구하라. 행렬과 벡터 데이터는 다음과 같이 얻을 수 있다.

```
from sklearn.datasets import load_boston
boston = load_boston()
X = boston.data
y = boston.target
```

행렬  $X$ 의 각 열이 의미하는 바는 다음과 같다.

1. CRIM: 범죄율
2. INDUS: 비소매상업지역 면적 비율
3. NOX: 일산화질소 농도
4. RM: 주택당 방 수
5. LSTAT: 인구 중 하위 계층 비율
6. B: 인구 중 흑인 비율
7. PTRATIO: 학생/교사 비율
8. ZN: 25,000 평방피트를 초과 거주지역 비율
9. CHAS: 찰스강의 경계에 위치한 경우는 1, 아니면 0
10. AGE: 1940년 이전에 건축된 주택의 비율
11. RAD: 방사형 고속도로까지의 거리
12. DIS: 보스턴 직업 센터 5곳까지의 가중평균거리
13. TAX: 재산세율

이렇게 구한 가중치 벡터의 각 원소의 부호가 우리의 직관이나 경험과 일치하는지 살펴보라. 또 연습문제 2.4.5에서 구한 값과 어떻게 달라지는지 살펴보라.