

## 3.4 특잇값 분해

정방행렬은 고유분해로 고윳값과 고유벡터를 찾을 수 있었다. 정방행렬이 아닌 행렬은 고유분해가 불가능하다. 하지만 대신 고유분해와 비슷한 특이분해를 할 수 있다.

### 특잇값과 특이벡터

$N \times M$  크기의 행렬  $A$ 를 다음과 같은 3개의 행렬의 곱으로 나타내는 것을 **특이분해(singular-decomposition)** 또는 **특잇값 분해(singular value decomposition)**라고 한다.

$$A = U\Sigma V^T \quad (3.4.1)$$

여기에서  $U, \Sigma, V$ 는 다음 조건을 만족해야 한다.

- 대각성분이 양수인 대각행렬이어야 한다. 큰 수부터 작은 수 순서로 배열한다.

$$\Sigma \in \mathbf{R}^{N \times M} \quad (3.4.2)$$

- $U$ 는  $N$ 차원 정방행렬로 모든 열벡터가 단위벡터이고 서로 직교해야 한다.

$$U \in \mathbf{R}^{N \times N} \quad (3.4.3)$$

- $V$ 는  $M$ 차원 정방행렬로 모든 열벡터가 단위벡터이고 서로 직교해야 한다.

$$V \in \mathbf{R}^{M \times M} \quad (3.4.4)$$

위 조건을 만족하는 행렬  $\Sigma$ 의 대각성분들을 **특잇값(singular value)**, 행렬  $U$ 의 열벡터들을 **왼쪽 특이벡터(left singular vector)**, 행렬  $V$ 의 행벡터들을 **오른쪽 특이벡터(right singular vector)**라고 부른다.

**[정리]** 특이분해는 모든 행렬에 대해 가능하다. 즉 어떤 행렬이 주어져더라도 위와 같이 특이분해할 수 있다.

증명은 이 책의 범위를 벗어나므로 생략한다.

### 특이값 분해 행렬의 크기

특잇값의 개수는 행렬의 열과 행의 개수 중 작은 값과 같다. 특이분해된 형태를 구체적으로 쓰면 다음과 같다.

만약  $N > M$ 이면  $\Sigma$  행렬이  $M$ 개의 특잇값(대각성분)을 가지고 다음처럼 아랫 부분이 영행렬이 된다.

$$A = \begin{bmatrix} \boxed{u_1} & \boxed{u_2} & \boxed{u_3} & \cdots & \boxed{u_M} & \cdots & \boxed{u_N} \end{bmatrix} \begin{bmatrix} \boxed{\sigma_1} & 0 & 0 & \cdots & 0 \\ 0 & \boxed{\sigma_2} & 0 & \cdots & 0 \\ 0 & 0 & \boxed{\sigma_3} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \boxed{\sigma_M} \\ 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & 0 & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \end{bmatrix}$$

반대로  $N < M$ 이면  $\Sigma$  행렬이  $N$ 개의 특잇값(대각성분)을 가지고 다음처럼 오른쪽 부분이 영행렬이 된다.

$$A = \begin{bmatrix} \boxed{u_1} & \boxed{u_2} & \cdots & \boxed{u_N} \end{bmatrix} \begin{bmatrix} \boxed{\sigma_1} & 0 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & \boxed{\sigma_2} & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & 0 & \boxed{\sigma_3} & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & & \vdots \\ 0 & 0 & 0 & \cdots & \boxed{\sigma_N} & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \\ \boxed{\phantom{0}} \end{bmatrix}$$

행렬의 크기만 표시하면 다음과 같다.

$$\begin{matrix} & \overbrace{\hspace{1cm}}^M \\ N \left\{ \begin{array}{|c|} \hline A \\ \hline \end{array} \right. & = N \left\{ \begin{array}{|c|c|} \hline \overbrace{\hspace{1cm}}^N & \overbrace{\hspace{1cm}}^M \\ \hline U & \Sigma \end{array} \right. \overbrace{\hspace{1cm}}^{\overbrace{\hspace{1cm}}^M} \left. \begin{array}{|c|} \hline V^T \\ \hline \end{array} \right\} M \end{matrix} \tag{3.4.7}$$

또는

$$\begin{matrix} & \overbrace{\hspace{1cm}}^M \\ N \left\{ \begin{array}{|c|} \hline A \\ \hline \end{array} \right. & = N \left\{ \begin{array}{|c|c|} \hline \overbrace{\hspace{1cm}}^N & \overbrace{\hspace{1cm}}^M \\ \hline U & \Sigma \end{array} \right. \overbrace{\hspace{1cm}}^{\overbrace{\hspace{1cm}}^M} \left. \begin{array}{|c|} \hline V^T \\ \hline \end{array} \right\} M \end{matrix}$$

예제

행렬  $A$

$$A = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \tag{3.4.9}$$

는 다음처럼 특이분해할 수 있다.

$$A = \begin{bmatrix} -\frac{1}{\sqrt{6}} & \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{6}} \\ -\frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{30}} \\ -\frac{1}{\sqrt{6}} & 0 & \frac{5}{\sqrt{30}} \end{bmatrix} \begin{bmatrix} \sqrt{12} & 0 \\ 0 & \sqrt{10} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \tag{3.4.10}$$

특잇값 분해의 축소형

특잇값 대각행렬에서 0인 부분은 사실상 아무런 의미가 없기 때문에 대각행렬의 0 원소 부분과 이에 대응하는 왼쪽(혹은 오른쪽) 특이벡터들을 없애고 다음처럼 축소된 형태로 해도 마찬가지로 원래 행렬이 나온다.

$N$ 이  $M$ 보다 큰 경우에는 왼쪽 특이벡터 중에서  $u_{M+1}, \dots, u_N$ 을 없앤다.

$$A = \begin{bmatrix} | & | & & | \\ u_1 & u_2 & \cdots & u_M \\ | & | & & | \end{bmatrix} \begin{bmatrix} \boxed{\sigma_1} & 0 & 0 & \cdots & 0 \\ 0 & \boxed{\sigma_2} & 0 & \cdots & 0 \\ 0 & 0 & \boxed{\sigma_3} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \boxed{\sigma_M} \end{bmatrix} \begin{bmatrix} \boxed{v_1^T} \\ \boxed{v_2^T} \\ \vdots \\ \boxed{v_M^T} \end{bmatrix}$$

$N$ 이  $M$ 보다 작은 경우에는 오른쪽 특이벡터 중에서  $v_{N+1}, \dots, v_M$ 을 없앤다.

$$A = \begin{bmatrix} | & | & & | \\ u_1 & u_2 & \cdots & u_N \\ | & | & & | \end{bmatrix} \begin{bmatrix} \boxed{\sigma_1} & 0 & 0 & \cdots & 0 \\ 0 & \boxed{\sigma_2} & 0 & \cdots & 0 \\ 0 & 0 & \boxed{\sigma_3} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \boxed{\sigma_N} \end{bmatrix} \begin{bmatrix} \boxed{v_1^T} \\ \boxed{v_2^T} \\ \vdots \\ \boxed{v_N^T} \end{bmatrix}$$

축소형의 경우에도 행렬의 크기만 표시하면 다음과 같다.

$$\begin{matrix} & \overbrace{\hspace{1cm}}^M \\ N \left\{ \begin{matrix} | \\ | \\ | \\ | \\ | \end{matrix} \right. & A & = & N \left\{ \begin{matrix} | \\ | \\ | \\ | \\ | \end{matrix} \right. & U & \begin{matrix} \overbrace{\hspace{1cm}}^M & \overbrace{\hspace{1cm}}^M \\ \boxed{\Sigma} & \boxed{V^T} \end{matrix} & \left. \vphantom{\begin{matrix} | \\ | \\ | \\ | \\ | \end{matrix}} \right\}^M \end{matrix} \quad (3.4.13)$$

또는

$$\begin{matrix} & \overbrace{\hspace{1cm}}^M \\ N \left\{ \begin{matrix} | \\ | \\ | \\ | \\ | \end{matrix} \right. & A & = & N \left\{ \begin{matrix} \overbrace{\hspace{1cm}}^N & \overbrace{\hspace{1cm}}^N & \overbrace{\hspace{1cm}}^M \\ \boxed{U} & \boxed{\Sigma} & \boxed{V^T} \end{matrix} \right. & \left. \vphantom{\begin{matrix} | \\ | \\ | \\ | \\ | \end{matrix}} \right\}^N \end{matrix} \quad (3.4)$$

## 예제

행렬  $A$

$$A = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \quad (3.4.15)$$

의 특이분해 축소형은 다음과 같다.

$$A = \begin{bmatrix} -\frac{1}{\sqrt{6}} & \frac{2}{\sqrt{5}} \\ -\frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{5}} \\ -\frac{1}{\sqrt{6}} & 0 \end{bmatrix} \begin{bmatrix} \sqrt{12} & 0 \\ 0 & \sqrt{10} \end{bmatrix} \begin{bmatrix} -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \quad (3.4.16)$$

## 파이썬을 사용한 특이분해

numpy.linalg 서브패키지와 scipy.linalg 서브패키지에서는 특이분해를 할 수 있는 `svd()` 명령을 제공한다. 오른쪽 특이행렬은 전치행렬로 출력된다는 점에 주의하라.

In [1]:

```
from numpy.linalg import svd

A = np.array([[3, -1], [1, 3], [1, 1]])
U, S, VT = svd(A)
```

In [2]:

```
U
```

Out[2]:

```
array([[ -4.08248290e-01,  8.94427191e-01, -1.82574186e-01],
       [-8.16496581e-01, -4.47213595e-01, -3.65148372e-01],
       [-4.08248290e-01, -2.06937879e-16,  9.12870929e-01]])
```

In [3]:

```
S
```

Out[3]:

```
array([3.46410162, 3.16227766])
```

In [4]:

```
np.diag(S, 1)[:, 1:]
```

Out[4]:

```
array([[3.46410162, 0.          ],
       [0.          , 3.16227766],
       [0.          , 0.          ]])
```

In [5]:

```
VT
```

Out[5]:

```
array([[ -0.70710678, -0.70710678],
       [ 0.70710678, -0.70710678]])
```

In [6]:

```
U @ np.diag(S, 1)[: , 1:] @ VT
```

Out[6]:

```
array([[ 3., -1.],
       [ 1.,  3.],
       [ 1.,  1.]])
```

축소형을 구하려면 인수 full\_matrices=False 로 지정한다.

In [7]:

```
U2, S2, VT2 = svd(A, full_matrices=False)
```

In [8]:

```
U2
```

Out[8]:

```
array([[ -4.08248290e-01,  8.94427191e-01],
       [ -8.16496581e-01, -4.47213595e-01],
       [ -4.08248290e-01, -2.06937879e-16]])
```

In [9]:

```
S2
```

Out[9]:

```
array([3.46410162, 3.16227766])
```

In [10]:

```
VT2
```

Out[10]:

```
array([[ -0.70710678, -0.70710678],
       [ 0.70710678, -0.70710678]])
```

In [11]:

```
U2 @ np.diag(S2) @ VT2
```

Out[11]:

```
array([[ 3., -1.],
       [ 1.,  3.],
       [ 1.,  1.]])
```

### 연습 문제 3.4.1

NumPy를 사용하여 다음 행렬을 특잇값 분해를 한다(축소형이 아닌 방법과 축소형 방법을 각각 사용한다). 또한 다시 곱해서 원래의 행렬이 나오는 것을 보여라.

$$B = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{bmatrix} \quad (3.4.17)$$

$$C = \begin{bmatrix} 2 & 4 \\ 1 & 3 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \quad (3.4.18)$$

### 특잇값과 특이벡터의 관계

행렬  $V$ 는 정규직교(orthonormal)행렬이므로 전치행렬이 역행렬이다.

$$V^T = V^{-1} \quad (3.4.19)$$

특이분해된 등식의 양변에  $V$ 를 곱하면,

$$AV = U\Sigma V^T V = U\Sigma \quad (3.4.20)$$

$$A \begin{bmatrix} v_1 & v_2 & \cdots & v_M \end{bmatrix} = \begin{bmatrix} u_1 & u_2 & \cdots & u_N \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & \cdots \\ 0 & \sigma_2 & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix} \quad (3.4.21)$$

행렬  $A$ 를 곱하여 정리하면  $M$ 이  $N$ 보다 클 때는

$$\begin{bmatrix} Av_1 & Av_2 & \cdots & Av_N \end{bmatrix} = \begin{bmatrix} \sigma_1 u_1 & \sigma_2 u_2 & \cdots & \sigma_N u_N \end{bmatrix} \quad (3.4.22)$$

이 되고  $N$ 이  $M$ 보다 클 때는

$$\begin{bmatrix} Av_1 & Av_2 & \cdots & Av_M \end{bmatrix} = \begin{bmatrix} \sigma_1 u_1 & \sigma_2 u_2 & \cdots & \sigma_M u_M \end{bmatrix} \quad (3.4.23)$$

이 된다.

즉,  $i$ 번째 특잇값  $\sigma_i$ 와 특이벡터  $u_i, v_i$ 는 다음과 같은 관계가 있다.

$$Av_i = \sigma_i u_i \quad (i = 1, \dots, \min(M, N)) \quad (3.4.24)$$

이 관계는 고유분해와 비슷하지만 고유분해와는 달리 좌변과 우변의 벡터가 다르다.

### 예제

위에서 예로 들었던 행렬의 경우,

$$\begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} = \sqrt{12} \begin{bmatrix} -\frac{1}{\sqrt{6}} \\ -\frac{2}{\sqrt{6}} \\ -\frac{1}{\sqrt{6}} \end{bmatrix} \quad (3.4.25)$$

$$\begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} = \sqrt{10} \begin{bmatrix} \frac{2}{\sqrt{5}} \\ -\frac{1}{\sqrt{5}} \\ 0 \end{bmatrix} \quad (3.4.26)$$

가 성립한다.

### 연습 문제 3.4.2

NumPy를 사용하여 다음 행렬에 대해

$$Av_i = \sigma_i u_i \quad (3.4.27)$$

가 성립한다는 것을 계산으로 보여라.

$$B = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{bmatrix} \quad (3.4.28)$$

$$C = \begin{bmatrix} 2 & 4 \\ 1 & 3 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \quad (3.4.29)$$

## 특이분해와 고유분해의 관계

행렬  $A$ 의 분산행렬  $A^T A$ 는

$$A^T A = (V \Sigma^T U^T)(U \Sigma V^T) = V \Lambda V^T \quad (3.4.30)$$

가 되어 행렬  $A$ 의 특잇값의 제곱(과 0)이 분산행렬  $A^T A$ 의 고유값, 행렬  $A$ 의 오른쪽 특이벡터가 분산행렬  $A^T A$ 의 고유벡터가 된다.

위 식에서  $\Lambda$ 은  $N$ 이  $M$ 보다 크면

$$\Lambda = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_M^2 \end{bmatrix} \quad (3.4.31)$$

이고  $N$ 이  $M$ 보다 작으면

$$\Lambda = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & \sigma_N^2 & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & \cdots & 0 \end{bmatrix} = \text{diag}(\sigma_1^2, \sigma_2^2, \cdots, \sigma_N^2, 0, \cdots, 0) \quad (3.4.32)$$

이다.

마찬가지 방법으로 행렬  $A$ 의 왼쪽 특이벡터가 행렬  $AA^T$ 의 고유벡터가 된다는 것을 증명할 수 있다.

In [12]:

```
w, V = np.linalg.eig(A.T @ A)
```



In [13]:

```
w # A.T A의 고유값
```

Out[13]:

```
array([12., 10.])
```

In [14]:

```
S ** 2 # A의 특잇값의 제곱
```

Out[14]:

```
array([12., 10.])
```

In [15]:

```
V # A.T A의 고유벡터
```

Out[15]:

```
array([[ 0.70710678, -0.70710678],
       [ 0.70710678,  0.70710678]])
```

In [16]:

```
VT.T # A의 오른쪽 특이벡터
```

Out[16]:

```
array([[ -0.70710678,  0.70710678],
       [ -0.70710678, -0.70710678]])
```

### 연습 문제 3.4.3

NumPy를 사용하여 행렬  $A$ 의 왼쪽 특이벡터가 행렬  $AA^T$ 의 고유벡터가 된다는 것을 보여라.

$$A = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \quad (3.4.33)$$

## 1차원 근사


2차원 평면 위에 3개의 2차원 벡터  $a_1, a_2, a_3$ 가 있다. 원점을 지나면서 모든 점들과 가능한 한 가까이 있는 직선을 만들고 싶다면 직선의 방향을 어떻게 해야 할까? 직선의 방향을 나타내는 단위 벡터를  $w$ 라고 하자.

In [17]:

```
w = np.array([2, 1]) / np.sqrt(5)
a1 = np.array([3, -1])
a2 = np.array([1, 3])
a3 = np.array([1, 1])

black = {"facecolor": "black"}

plt.figure(figsize=(9, 6))
plt.plot(0, 0, 'kP', ms=10)
plt.annotate('', xy=w, xytext=(0, 0), arrowprops=black)
plt.plot([-2, 8], [-1, 4], 'b--', lw=2)
plt.plot([a1[0], 2], [a1[1], 1], 'g:', lw=2)
plt.plot([a2[0], 2], [a2[1], 1], 'g:', lw=2)
plt.plot([a3[0], 1.2], [a3[1], 0.6], 'g:', lw=2)
plt.plot(a1[0], a1[1], 'ro', ms=10)
plt.plot(a2[0], a2[1], 'ro', ms=10)
plt.plot(a3[0], a3[1], 'ro', ms=10)
plt.text(0.1, 0.5, "$w$")
plt.text(a1[0] + 0.2, a1[1] + 0.2, "$a_1$")
plt.text(a2[0] + 0.2, a2[1] + 0.2, "$a_2$")
plt.text(a3[0] - 0.3, a3[1] + 0.2, "$a_3$")
plt.xticks(np.arange(-3, 15))
plt.yticks(np.arange(-1, 5))
plt.xlim(-3, 6)
plt.ylim(-2, 4)
plt.show()
```



벡터  $w$ 와 점  $a_i$ 의 거리의 제곱은 다음처럼 계산할 수 있다.(연습 문제 3.1.9)

$$\|a_i^\perp w\|^2 = \|a_i\|^2 - \|a_i^{\parallel w}\|^2 = \|a_i\|^2 - (a_i^T w)^2 \quad (3.4.34)$$

벡터  $a_1, a_2, a_3$ 를 행벡터로 가지는 행렬  $A$ 를 가정하면

$$A = \begin{bmatrix} a_1^T \\ a_2^T \\ a_3^T \end{bmatrix} \quad (3.4.35)$$

행벡터의 놈의 제곱의 합은 행렬의 놈이므로 모든 점들과의 거리의 제곱의 합은 행렬의 놈으로 계산된다. (연습 문제 2.3.2)

$$\begin{aligned} \sum_{i=1}^3 \|a_i^\perp w\|^2 &= \sum_{i=1}^3 \|a_i\|^2 - \sum_{i=1}^3 (a_i^T w)^2 \\ &= \|A\|^2 - \|Aw\|^2 \end{aligned} \quad (3.4.36)$$

점  $a_i$ 의 위치가 고정되어 있으므로 행렬  $A$ 의 놈 값은 고정되어 있다. 따라서 이 값이 가장 작아지려면  $\|Aw\|^2$ 의 값이 가장 크게 만드는  $w$ 를 찾아야 한다. 이 문제는 다음처럼 수식으로 쓸 수 있다.

$$\arg \max_w \|Aw\|^2 \quad (3.4.37)$$

## 1차원 근사의 풀이

위에서 예로 든 행렬  $A \in \mathbf{R}^{3 \times 2}$  를 특이분해하면 2개의 특잇값, 왼쪽/오른쪽 특이벡터를 가진다. 이를 각각 다음처럼 이름붙인다.

- 첫 번째 특잇값:  $\sigma_1$ , 첫 번째 왼쪽 특이벡터  $u_1 \in \mathbf{R}^3$ , 첫 번째 오른쪽 특이벡터  $v_1 \in \mathbf{R}^2$
- 두 번째 특잇값:  $\sigma_2$ , 두 번째 왼쪽 특이벡터  $u_2 \in \mathbf{R}^3$ , 두 번째 오른쪽 특이벡터  $v_2 \in \mathbf{R}^2$

첫 번째 특잇값  $\sigma_1$ 은 두 번째 특잇값  $\sigma_2$ 보다 같거나 크다.

$$\sigma_1 \geq \sigma_2 \quad (3.4.38)$$

또한 위에서 알아낸 것처럼 A에 오른쪽 특이벡터를 곱하면 왼쪽 특이벡터 방향이 된다.

$$Av_1 = \sigma_1 u_1 \quad (3.4.39)$$

$$Av_2 = \sigma_2 u_2 \quad (3.4.40)$$

오른쪽 특이벡터  $v_1, v_2$ 는 서로 직교하므로 (같은 방향이 아니라서) 선형독립이고 2차원 평면공간의 기저벡터가 될 수 있다.

우리는  $\|Aw\|$ 의 값이 가장 크게 만드는  $w$ 를 찾아야 하는데  $w$ 는 2차원 벡터이므로 2차원 평면공간의 기저벡터인  $v_1, v_2$ 의 선형조합으로 표현할 수 있다.

$$w = w_1 v_1 + w_2 v_2 \quad (3.4.41)$$

단,  $w$ 도 단위벡터이므로  $w_1, w_2$ 는 다음 조건을 만족해야 한다.

$$w_1^2 + w_2^2 = 1 \quad (3.4.42)$$

이때  $\|Aw\|$ 의 값은

$$\begin{aligned} \|Aw\|^2 &= \|A(w_1 v_1 + w_2 v_2)\|^2 \\ &= \|w_1 Av_1 + w_2 Av_2\|^2 \\ &= \|w_1 \sigma_1 u_1 + w_2 \sigma_2 u_2\|^2 \\ &= \|w_1 \sigma_1 u_1\|^2 + \|w_2 \sigma_2 u_2\|^2 \quad (\text{orthogonal}) \\ &= w_1^2 \sigma_1^2 \|u_1\|^2 + w_2^2 \sigma_2^2 \|u_2\|^2 \\ &= w_1^2 \sigma_1^2 + w_2^2 \sigma_2^2 \quad (\text{unit vector}) \end{aligned} \quad (3.4.43)$$

$\sigma_1 > \sigma_2 > 0$  이므로  $w_1^2 + w_2^2 = 1$ 라는 조건을 만족하면서 위 값을 가장 크게 하는  $w_1, w_2$  값은

$$w_1 = 1, w_2 = 0 \quad (3.4.44)$$

이다. 즉, 첫 번째 오른쪽 특이벡터 방향으로 하는 것이다.

$$w = v_1 \quad (3.4.45)$$

이때  $\|Aw\|$ 는 첫 번째 특잇값이 된다.

$$\|Aw\| = \|Av_1\| = \|\sigma_1 u_1\| = \sigma_1 \|u_1\| = \sigma_1 \quad (3.4.46)$$

위에서 예로 들었던 행렬

$$A = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \tag{3.4.47}$$

첫 번째 오른쪽 특이벡터

$$v_1 = \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} \tag{3.4.48}$$

가 가장 거리의 합이 작은 방향이 된다. 그리고 이때의 거리의 제곱의 합은 다음과 같다.

$$\|A\|^2 - \|Aw\|^2 = \|A\|^2 - \sigma_1^2 \tag{3.4.49}$$

In [18]:

```
np.linalg.norm(A)**2 - S[0]**2
```

Out [18]:


9.999999999999998

In [19]:

```
w = np.array([1, 1]) / np.sqrt(2)
a1 = np.array([3, -1])
a2 = np.array([1, 3])
a3 = np.array([1, 1])

black = {"facecolor": "black"}

plt.figure(figsize=(9, 6))
plt.plot(0, 0, 'kP', ms=10)
plt.annotate('', xy=w, xytext=(0, 0), arrowprops=black)
plt.plot([-2, 4], [-2, 4], 'b--', lw=2)
plt.plot([a1[0], 1], [a1[1], 1], 'g:', lw=2)
plt.plot([a2[0], 2], [a2[1], 2], 'g:', lw=2)
plt.plot(a1[0], a1[1], 'ro', ms=10)
plt.plot(a2[0], a2[1], 'ro', ms=10)
plt.plot(a3[0], a3[1], 'ro', ms=10)
plt.text(0.1, 0.5, "$w$")
plt.text(a1[0] + 0.2, a1[1] + 0.2, "$a_1$")
plt.text(a2[0] + 0.2, a2[1] + 0.2, "$a_2$")
plt.text(a3[0] - 0.3, a3[1] + 0.2, "$a_3$")
plt.xticks(np.arange(-3, 15))
plt.yticks(np.arange(-1, 5))
plt.xlim(-3, 6)
plt.ylim(-2, 4)
plt.show()
```



## 일반적인 풀이

만약  $N = 3$ 이 아니라 일반적인 경우에는 다음처럼 풀 수 있다.

$$\begin{aligned}\|Aw\|^2 &= \sum_{i=1}^N (a_i^T w)^2 \\ &= \sum_{i=1}^N (a_i^T w)^T (a_i^T w) \\ &= \sum_{i=1}^N w^T a_i a_i^T w \\ &= w^T \left( \sum_{i=1}^N a_i a_i^T \right) w \\ &= w^T A^T A w\end{aligned}\tag{3.4.50}$$

분산행렬의 고유분해 공식을 이용하면,

$$\begin{aligned}w^T A^T A w &= w^T V \Lambda V^T w \\ &= w^T \left( \sum_{i=1}^M \sigma_i^2 v_i v_i^T \right) w \\ &= \sum_{i=1}^M \sigma_i^2 (w^T v_i) (v_i^T w) \\ &= \sum_{i=1}^M \sigma_i^2 \|v_i^T w\|^2\end{aligned}\tag{3.4.51}$$

이 된다. 이 식에서  $M$ 은 0이 아닌 특잇값 개수다.

즉, 우리가 풀어야 할 문제는 다음과 같다.

$$\arg \max_w \|Aw\|^2 = \arg \max_w \sum_{i=1}^M \sigma_i^2 \|v_i^T w\|^2\tag{3.4.52}$$

이 값을 가장 크게 하려면  $w$ 를 가장 큰 특잇값에 대응하는 오른쪽 고유벡터  $v_1$ 으로 해야 한다.

## 랭크-1 근사문제

또  $a_i$ 를  $w$ 에 투영한 벡터는

$$a_i^{\parallel w} = (a_i^T w)w \quad (3.4.53)$$

이므로  $w$  벡터를 이용하면  $N$ 개의  $M$ 차원 벡터  $a_1, a_2, \dots, a_N$  ( $a_i \in \mathbf{R}^M$ )를 1차원으로 투영(projection)하여 가장 비슷한  $N$ 개의 1차원 벡터  $a_1^{\parallel w}, a_2^{\parallel w}, \dots, a_N^{\parallel w}$  ( $a_i^{\parallel w} \in \mathbf{R}^1$ )를 만들 수 있다.

$$A' = \begin{bmatrix} (a_1^{\parallel w})^T \\ (a_2^{\parallel w})^T \\ \vdots \\ (a_N^{\parallel w})^T \end{bmatrix} = \begin{bmatrix} a_1^T w w^T \\ a_2^T w w^T \\ \vdots \\ a_N^T w w^T \end{bmatrix} = \begin{bmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_N^T \end{bmatrix} w w^T = A w w^T \quad (3.4.54)$$

이 답은 원래 행렬  $A$ 에 랭크-1 행렬  $w w^T$ 를 곱해서 원래의 행렬  $A$ 와 가장 비슷한 행렬  $A'$ 을 만드는 문제와 같다.

$$\arg \min_w \|A - A'\| = \arg \min_w \|A - A w w^T\| \quad (3.4.55)$$

따라서 문제를 **랭크-1 근사문제(rank-1 approximation problem)**라고도 한다.

## $K$ 차원 근사



이번에는  $N$ 개의  $M$ 차원 벡터  $a_1, a_2, \dots, a_N$  ( $a_i \in \mathbf{R}^M$ )를 1차원이 아니라 정규직교인 기저벡터  $w_1, w_2, \dots, w_K$ 로 이루어진  $K$ 차원 벡터공간으로 투영하여 가장 비슷한  $N$ 개의  $K$ 차원 벡터  $a_1^{\parallel w}, a_2^{\parallel w}, \dots, a_N^{\parallel w}$ 를 만들기 위한 정규직교 기저벡터  $w_1, w_2, \dots, w_K$ 를 찾는 문제를 생각하자. 이 문제는 랭크- $K$  근사문제라고 한다.

기저벡터행렬을  $W$ 라고 하자.

$$W = [w_1 \quad w_2 \quad \dots \quad w_K] \quad (3.4.56)$$

정규직교 기저벡터에 대한 벡터  $a_i$ 의 투영  $a_i^{\parallel w}$ 는 각 기저벡터에 대한 내적으로 만들 수 있다.

$$a_i^{\parallel w} = (a_i^T w_1)w_1 + (a_i^T w_2)w_2 + \dots + (a_i^T w_K)w_K = \sum_{k=1}^K (a_i^T w_k)w_k \quad (3.4.57)$$

벡터  $a_1, a_2, \dots, a_N$ 를 행벡터로 가지는 행렬  $A$ 를 가정하면

$$A = \begin{bmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_N^T \end{bmatrix} \quad (3.4.58)$$

모든 점들과의 거리의 제곱의 합은 다음처럼 행렬의 놈으로 계산할 수 있다.

$$\begin{aligned} \sum_{i=1}^N \|a_i^{\perp w}\|^2 &= \sum_{i=1}^N \|a_i\|^2 - \sum_{i=1}^N \|a_i^{\parallel w}\|^2 \\ &= \|A\|^2 - \sum_{i=1}^N \|a_i^{\parallel w}\|^2 \end{aligned} \quad (3.4.59)$$

행렬  $A$ 는 이미 주어져있으므로 이 값을 가장 작게 하려면 두 번째 항의 값을 가장 크게 하면 된다. 두 번째 항은  $K=1$ 일 때와 같은 방법으로 분산행렬 형태로 바꿀 수 있다.

$$\begin{aligned} \sum_{i=1}^N \|a_i^{\parallel w}\|^2 &= \sum_{i=1}^N \sum_{k=1}^K \|(a_i^T w_k)w_k\|^2 \\ &= \sum_{i=1}^N \sum_{k=1}^K \|a_i^T w_k\|^2 \\ &= \sum_{k=1}^K w_k^T A^T A w_k \end{aligned} \quad (3.4.60)$$

분산행렬의 고유분해를 사용하면

$$\begin{aligned} \sum_{k=1}^K w_k^T A^T A w_k &= \sum_{k=1}^K w_k^T V \Lambda V^T w_k \\ &= \sum_{k=1}^K w_k^T \left( \sum_{i=1}^M \sigma_i^2 v_i v_i^T \right) w_k \\ &= \sum_{k=1}^K \sum_{i=1}^M \sigma_i^2 \|v_i^T w_k\|^2 \end{aligned} \quad (3.4.61)$$

이 문제도 1차원 근사문제처럼 풀면 다음과 같은 답을 얻을 수 있다.

가장 큰  $K$ 개의 특잇값에 대응하는 오른쪽 특이벡터가 기저벡터일 때 가장 값이 커진다.

## 랭크-K 근사문제

우리가 찾아야 하는 것은 이 값을 가장 크게 하는  $K$ 개의 영벡터가 아닌 직교하는 단위벡터  $w_k$ 이다. 고유분해의 성질로부터 오른쪽 기저벡터 중 가장 큰  $K$ 개의 특잇값에 대응하는 오른쪽 특이벡터가 우리가 찾는 기저벡터가 된다.

이 문제는 다음처럼 랭크- $K$  근사문제의 형태로 만들 수도 있다.

$$\begin{aligned}
 a_i^{\|w} &= (a_i^T w_1)w_1 + (a_i^T w_2)w_2 + \cdots + (a_i^T w_K)w_K \\
 &= [w_1 \quad w_2 \quad \cdots \quad w_K] \begin{bmatrix} a_i^T w_1 \\ a_i^T w_2 \\ \vdots \\ a_i^T w_K \end{bmatrix} \\
 &= [w_1 \quad w_2 \quad \cdots \quad w_K] \begin{bmatrix} w_1^T \\ w_2^T \\ \vdots \\ w_K^T \end{bmatrix} a_i \\
 &= WW^T a_i
 \end{aligned} \tag{3.4.62}$$

이러한 투영벡터를 모아놓은 행렬  $A'$ 는

$$A' = \begin{bmatrix} (a_1^{\|w})^T \\ (a_2^{\|w})^T \\ \vdots \\ (a_N^{\|w})^T \end{bmatrix} = \begin{bmatrix} a_1^T WW^T \\ a_2^T WW^T \\ \vdots \\ a_N^T WW^T \end{bmatrix} = \begin{bmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_N^T \end{bmatrix} WW^T = AWW^T \tag{3.4.63}$$

따라서 이 문제는 원래 행렬  $A$ 에 랭크- $K$  행렬  $WW^T$ 를 곱해서 원래의 행렬  $A$ 와 가장 비슷한 행렬  $A'$ 을 만드는 문제와 같다.

$$\arg \min_{w_1, \dots, w_K} \|A - AWW^T\| \tag{3.4.64}$$