

## 8.6 다변수정규분포

$D$ 차원 다변수정규분포(MVN: multivariate Gaussian normal distribution)의 확률밀도함수는 평균벡터  $\mu$  와 공분산행렬  $\Sigma$  라는 두 개의 모수를 가지며 다음과 같은 수식으로 정의한다.

$$\mathcal{N}(x; \mu, \Sigma) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu)\right) \quad (8.6.1)$$

이 식에서 각 기호의 의미는 다음과 같다.

- $x \in \mathbf{R}^D$  확률변수벡터
- $\mu \in \mathbf{R}^D$  평균벡터
- $\Sigma \in \mathbf{R}^{D \times D}$  공분산행렬

다변수정규분포에서 공분산행렬은 양의 정부호인 대칭행렬이어야 한다. 따라서 역행렬이 항상 존재한다. 공분산행렬의 역행렬  $\Sigma^{-1}$  을 정밀도행렬(precision matrix)이라고 한다.

### 예제

다음과 같은 2차원( $D = 2$ ) 다변수정규분포를 생각하자. 2차원이므로 확률변수벡터는

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad (8.6.2)$$

이다.

만약 모수가 다음과 같다고 하자.

$$\mu = \begin{bmatrix} 2 \\ 3 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad (8.6.3)$$

공분산행렬로부터  $x_1$  과  $x_2$  가 독립이라는 것을 알 수 있다. 확률밀도함수를 구하면 다음과 같다.

$$|\Sigma| = 1, \quad \Sigma^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad (8.6.4)$$

$$\begin{aligned} (x - \mu)^T \Sigma^{-1} (x - \mu) &= \begin{bmatrix} x_1 - 2 & x_2 - 3 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 - 2 \\ x_2 - 3 \end{bmatrix} \\ &= (x_1 - 2)^2 + (x_2 - 3)^2 \end{aligned} \quad (8.6.5)$$

$$\mathcal{N}(x_1, x_2) = \frac{1}{2\pi} \exp\left(-\frac{1}{2}((x_1 - 2)^2 + (x_2 - 3)^2)\right) \quad (8.6.6)$$

확률밀도함수값이 같은 등고선은 원이 된다.

$$(x_1 - 2)^2 + (x_2 - 3)^2 = r^2 \quad (8.6.7)$$

사이파이의 stats 서브패키지는 다변수정규분포를 위한 `multivariate_normal()` 명령을 제공한다. `mean` 인수로 평균벡터를, `cov` 인수로 공분산행렬을 받는다. `multivariate_normal()` 명령으로 위 확률밀도함수를 그리고 랜덤 표본을 생성하면 다음 그림과 같다.

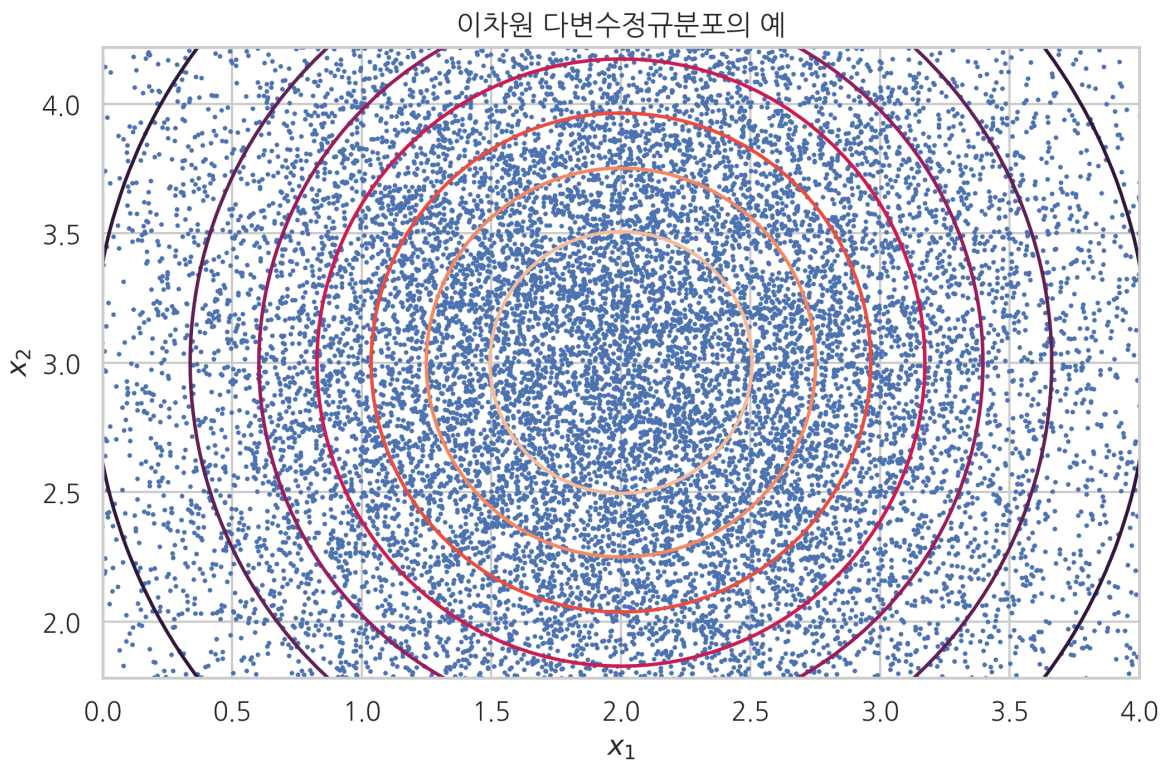
In [1]:

```
mu = [2, 3]
cov = [[1, 0], [0, 1]]

rv = sp.stats.multivariate_normal(mu, cov)
X = rv.rvs(20000)

xx = np.linspace(-1, 6, 120)
yy = np.linspace(-1, 6, 150)
XX, YY = np.meshgrid(xx, yy)

plt.scatter(X[:, 0], X[:, 1], s=1)
plt.contour(XX, YY, rv.pdf(np.dstack([XX, YY])))
plt.axis("equal")
plt.xlim(0, 4)
plt.ylim(2, 4)
plt.xlabel("$x_1$")
plt.ylabel("$x_2$")
plt.title("이차원 다변수정규분포의 예")
plt.show()
```



### 예제

만약 모수가 다음과 같다고 하자. 공분산행렬로부터  $x_1$  과  $x_2$  가 양의 상관관계가 있다는 것을 알 수 있다.

$$\mu = \begin{bmatrix} 2 \\ 3 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 2 & 3 \\ 3 & 7 \end{bmatrix} \quad (8.6.8)$$

이 때 확률밀도함수는 다음과 같다.

$$|\Sigma| = 5, \quad \Sigma^{-1} = \begin{bmatrix} 1.4 & -0.6 \\ -0.6 & 0.4 \end{bmatrix} \quad (8.6.9)$$

$$\begin{aligned} (x - \mu)^T \Sigma^{-1} (x - \mu) &= \begin{bmatrix} x_1 - 2 & x_2 - 3 \end{bmatrix} \begin{bmatrix} 1.4 & -0.6 \\ -0.6 & 0.4 \end{bmatrix} \begin{bmatrix} x_1 - 2 \\ x_2 - 3 \end{bmatrix} \\ &= \frac{7}{5}(x_1 - 2)^2 - \frac{6}{5}(x_1 - 2)(x_2 - 3) + \frac{2}{5}(x_2 - 3)^2 \end{aligned} \quad (8.6.10)$$

$$\mathcal{N}(x_1, x_2) = \frac{1}{2\sqrt{5}\pi} \exp\left(\frac{7}{5}(x_1 - 2)^2 - \frac{6}{5}(x_1 - 2)(x_2 - 3) + \frac{2}{5}(x_2 - 3)^2\right) \quad (8.6.11)$$

이 확률밀도함수의 모양은 다음과 같이 회전변환된 타원 모양이 된다.

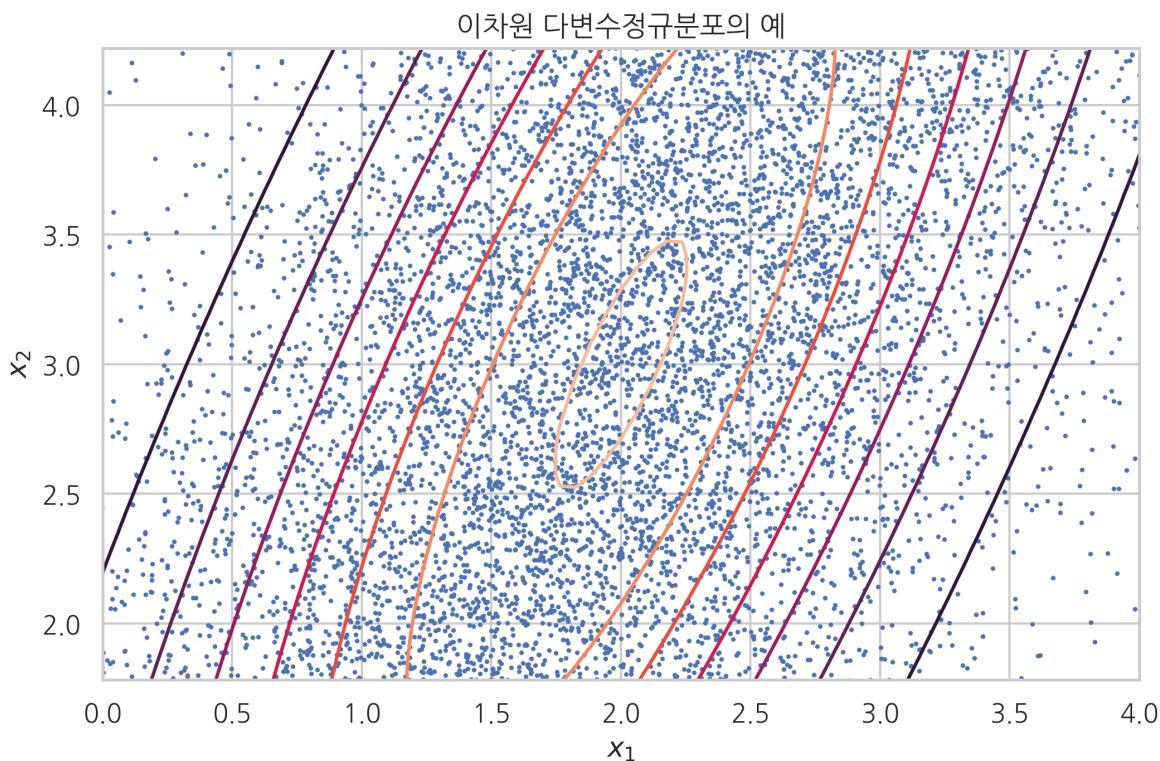
In [2]:

```
mu = [2, 3]
cov = [[2, 3], [3, 7]]

rv = sp.stats.multivariate_normal(mu, cov)
X = rv.rvs(20000)

xx = np.linspace(-1, 6, 120)
yy = np.linspace(-1, 6, 150)
XX, YY = np.meshgrid(xx, yy)

plt.scatter(X[:, 0], X[:, 1], s=1)
plt.contour(XX, YY, rv.pdf(np.dstack([XX, YY])))
plt.axis("equal")
plt.xlim(0, 4)
plt.ylim(2, 4)
plt.xlabel("$x_1$")
plt.ylabel("$x_2$")
plt.title("이차원 다변수정규분포의 예")
plt.show()
```



## 다변수정규분포와 고윳값 분해

다변수정규분포의 공분산행렬  $\Sigma$ 은 양의 정부호인 대칭행렬이므로 대각화가능(diagonalizable)이다. 정밀도행렬  $\Sigma^{-1}$ 은 다음처럼 분해할 수 있다. 이 식에서  $\Lambda$ 는 고윳값행렬,  $V$ 는 고유벡터행렬이다.

$$\Sigma^{-1} = V\Lambda^{-1}V^T \quad (8.6.12)$$

이를 이용하면 확률밀도함수는 다음처럼 좌표 변환할 수 있다.

$$\begin{aligned} \mathcal{N}(x) &\propto \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right) \\ &= \exp\left(-\frac{1}{2}(x - \mu)^T V\Lambda^{-1}V^T(x - \mu)\right) \\ &= \exp\left(-\frac{1}{2}(V^T(x - \mu))^T \Lambda^{-1}(V^T(x - \mu))\right) \\ &= \exp\left(-\frac{1}{2}(V^{-1}(x - \mu))^T \Lambda^{-1}(V^{-1}(x - \mu))\right) \end{aligned} \quad (8.6.13)$$

이 식에서

$$x' = V^{-1}(x - \mu) \quad (8.6.14)$$

라고 하자. 이 식은 변환행렬  $V^{-1}$ 의 열벡터인 고유벡터를 새로운 축으로 가지도록 회전하고  $\mu$ 벡터 방향으로 평행이동하는 것을 뜻한다.

최종 확률밀도함수식은 다음과 같다. 이 식에서  $\Lambda$ 는 고윳값  $\lambda_i$ 를 대각성분으로 가지는 대각행렬이므로 새로운 좌표  $x'$ 에서 확률밀도함수는 타원이 된다. 타원의 반지름은 고윳값 크기에 비례한다. 반대로 이야기하면 원래 좌표에서 확률밀도함수는  $\mu$ 를 중심으로 가지고 고윳값에 비례하는 반지름을 가진 타원을 고유벡터 방향으로 회전 시킨 모양이다.

$$\begin{aligned} \mathcal{N}(x) &\propto \exp\left(-\frac{1}{2}x'^T \Lambda^{-1}x'\right) \\ &\propto \exp\left(-\frac{x_1'^2}{\lambda_1^2} - \frac{x_2'^2}{\lambda_2^2} - \dots - \frac{x_D'^2}{\lambda_D^2}\right) \end{aligned} \quad (8.6.15)$$

예를 들어 위의 두번째 예제에서 공분산행렬을 고유분해하면 다음과 같다.

In [3]:

```
mu = [2, 3]
cov = [[4, 3], [3, 5]]
w, V = np.linalg.eig(cov)
```

고윳값은  $\lambda_1 = 1.46$ ,  $\lambda_2 = 7.54$ 다.

In [4]:

```
w
```

Out[4]:

```
array([1.45861873, 7.54138127])
```

고유벡터는  $v_1 = (-0.763, 0.646)$ ,  $v_2 = (-0.646, -0.763)$ 이다.

In [5]:

V

Out [5]:

```
array([[ -0.76301998, -0.6463749 ],  
       [ 0.6463749 , -0.76301998]])
```

따라서 확률밀도함수가 고유벡터  $v_1 = (-0.763, 0.646)$ 와  $v_2 = (-0.646, -0.763)$ 를 축으로하는 타원형임을 알 수 있다

In [6]:


```
plt.figure(figsize=(8, 4))

d = dict(facecolor="k", edgecolor="k", width=2)

plt.subplot(121)
xx = np.linspace(-1, 5, 120)
yy = np.linspace(0, 6, 150)
XX, YY = np.meshgrid(xx, yy)
rv1 = sp.stats.multivariate_normal(mu, cov)
plt.contour(XX, YY, rv1.pdf(np.dstack([XX, YY])))
plt.annotate("", xy=(mu + 0.35 * w[0] * V[:, 0]), xytext=mu, arrowprops=d)
plt.annotate("", xy=(mu + 0.35 * w[1] * V[:, 1]), xytext=mu, arrowprops=d)
plt.scatter(mu[0], mu[1], s=10, c="k")
plt.axis("equal")
plt.xlabel("$x_1$")
plt.ylabel("$x_2$")
plt.title("$x_1, x_2$좌표의 결합확률밀도함수")

plt.subplot(122)
xx = np.linspace(-3, 3, 120)
yy = np.linspace(-3, 3, 150)
XX, YY = np.meshgrid(xx, yy)
rv2 = sp.stats.multivariate_normal((0,0), w) # 좌표 변환
plt.contour(XX, YY, rv2.pdf(np.dstack([XX, YY])))
plt.annotate("", xy=(0.35 * w[0] * np.array([1, 0])), xytext=(0,0), arrowprops=d)
plt.annotate("", xy=(0.35 * w[1] * np.array([0, 1])), xytext=(0,0), arrowprops=d)
plt.scatter(0, 0, s=10, c="k")
plt.axis("equal")
plt.xlabel("$x'_1$")
plt.ylabel("$x'_2$")
plt.title("$x'_1, x'_2$좌표의 결합확률밀도함수")

plt.tight_layout()
plt.show()
```



### 연습 문제 8.6.1

다음과 같은 평균벡터와 공분산행렬을 가지는 2차원 다변수정규분포의 확률밀도함수의 모양은 어떻게 되는가?

$$\mu = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 4 & -3 \\ -3 & 4 \end{bmatrix} \quad (8.6.16)$$

## 다변수정규분포의 조건부확률분포

**[정리]** 다변수정규분포인 확률변수벡터 중 어떤 원소의 값이 주어지면 다른 확률변수의 조건부 확률분포는 다변수정규분포다.

즉 다변수정규분포 확률밀도함수를 자른 단면은 다변수정규분포가 된다.

예를 들어 확률변수  $X$ 의 값  $x$ 를 두 벡터  $x_1$ 과  $x_2$ 로 나누었을 때

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad (8.6.17)$$

$x_2$  값이 주어지면(관측되면),  $X_1$ 만의 확률밀도함수가 다변수정규분포를 이루는 것을 증명하자.

$x_1$ 과  $x_2$ 에 따라 기댓값벡터도  $\mu_1$ 과  $\mu_2$ 로 나뉘어진다.

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} \quad (8.6.18)$$

공분산행렬  $\Sigma$ 도 다음처럼 나뉘어진다.

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \quad (8.6.19)$$

공분산행렬의 역행렬인 정밀도행렬  $\Lambda$ 도 마찬가지로 분할한다.

$$\Lambda = \Sigma^{-1} = \begin{bmatrix} \Lambda_{11} & \Lambda_{12} \\ \Lambda_{21} & \Lambda_{22} \end{bmatrix} \quad (8.6.20)$$

이 때  $\Sigma$ 와  $\Lambda$ 가 대칭행렬이므로  $\Lambda_{11}$ 와  $\Lambda_{22}$ 도 대칭행렬이고  $\Lambda_{12} = \Lambda_{21}$ 이다.

이를 적용하면

$$(x - \mu)^T \Sigma^{-1} (x - \mu) = (x_1 - \mu_{1|2})^T \Lambda_{11} (x_1 - \mu_{1|2}) + C(x_2, \mu, \Sigma) \quad (8.6.21)$$

가 된다. 이 식에서 조건부기댓값  $\mu_{1|2}$ 는

$$\mu_{1|2} = \mu_1 - \Lambda_{11}^{-1} \Lambda_{12} (x_2 - \mu_2) \quad (8.6.22)$$

이다.  $C$ 는  $x_1$ 을 포함하지 않은 항을 가리키며 다음과 같다.

$$\begin{aligned} C &= \mu_1^T \Lambda_{11} \mu_1 - 2\mu_1^T \Lambda_{12} (x_2 - \mu_2) + (x_2 - \mu_2)^T \Lambda_{22} (x_2 - \mu_2) \\ &\quad - (x_2 - \mu_2)^T \Lambda_{12}^T \Lambda_{11}^{-1} \Lambda_{12} (x_2 - \mu_2) \end{aligned} \quad (8.6.23)$$

이 식에 지수함수를 적용하면

$$p(x_1|x_2) = C' \exp((x_1 - \mu_{1|2})^T \Lambda_{11} (x_1 - \mu_{1|2})) \quad (8.6.24)$$

가 된다. 이 식에서  $C' = \exp C$ 다.

즉  $x_2$ 가 어떤 값으로 주어지면  $x_1$ 은 조건부기댓값  $\mu_{1|2}$ 와 조건부공분산행렬  $\Sigma_{1|2}$ 를 가지는 다변수정규분포가 된다.  $\Sigma_{1|2}$ 은 분할행렬의 역행렬공식으로부터 다음과 같다.

$$\Sigma_{1|2} = \Lambda_{11}^{-1} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \quad (8.6.25)$$




그림 8.6.1 : 다변수정규분포의 조건부확률분포

## 다변수정규분포의 주변확률분포

[정리] 다변수정규분포의 주변확률분포는 다변수정규분포다.

즉 결합확률밀도함수를 어떤 확률변수의 값으로 적분하여 나머지 확률변수의 주변확률분포를 구하면 다변수정규분포이다. 예를 들어  $x_1$ 과  $x_2$ 로 이루어진 결합 확률밀도함수  $p(x_1, x_2)$ 를  $x_2$ 로 적분하면  $x_1$ 의 주변확률분포는 정규분포가 된다.

$$p(x_1) = \int p(x_1, x_2)dx_2 = \mathcal{N}(x_1; \mu_1, \Sigma_{11}) \quad (8.6.26)$$

$x_2$ 의 주변확률분포는의 기댓값은 원래 기댓값벡터 중  $x_1$  성분과 같고 공분산행렬은 분할행렬 중  $\Sigma_{11}$  성분과 같다. 증명은 생략한다.

### 연습 문제 8.6.2

2차원 다변수정규분포가 다음과 같은 모수를 가진다고 하자.

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \quad (8.6.27)$$

(1)  $x_2$ 가 주어졌을 때  $x_1$ 의 조건부확률분포함수가 다음과 같음을 보여라.



$$\mathcal{N}\left(x_1 \mid \mu_1 + \frac{\rho\sigma_1\sigma_2}{\sigma_2^2}(x_2 - \mu_2), \sigma_1^2 - \frac{(\rho\sigma_1\sigma_2)^2}{\sigma_2^2}\right) \quad (8.6.28)$$